Reconocimiento Automático de Modulaciones Usando KNN, K-Means de Machine Learning y CNN, RNN de Deep Learning

Anggie Valeria Cerón Cardona
Universidad del Quindío
Ingeniería Electrónica
anggiev.ceronc@uqvirtual.edu.co

Juan Andrés Moncada Restrepo
Universidad del Quindío
Ingeniería Electrónica
juana.moncadar@uqvirtual.edu.co

Msc. Wilmer Diego Jimenez Trujillo
Universidad del Quindío
Ingeniería Electrónica
wdjimenez@uniquindio.edu.co

***Resumen*—El reconocimiento automático de modulaciones (AMC) es una técnica fundamental en sistemas modernos de comunicaciones inalámbricas, especialmente en aplicaciones como radio cognitiva y monitereo espectral. En este documento se realiza un análisis comparativo entre modelos de *Machine Learning* y *Deep Learning* aplicados a la clasificación de modulaciones utilizando los datasets RadioML 2016 y RadioML 2018. El proyecto RadioML consta de un conjunto de datos ampliamente utilizado en el área de procesamiento de señales de radio y aprendizaje automático para reconocimiento de señales (Radio Frequency Machine Learning). Para *Machine Learning* se implementaron algoritmos KNN y K-Means, incorporando diferentes técnicas de procesamiento. Además, para *Deep Learning* se emplearon arquitecturas CNN y RNN con el fin de analizar su capacidad de extracción automáticas de características y clasificación de señales bajo diferentes condiciones de ruido. Finalmente se evaluó el comportamiento de los modelos mediante métricas de desempeño, precisión y capacidad de generalización, identificando las ventajas y limitaciones de cada enfoque en tareas de reconocimiento automático de modulaciones.**

***Términos clave*—Modulaciones, KNN, K-Means, CNN, RNN, PCA, RadioML**

I. Introducción

En los últimos años, los conjuntos de datos RadioML se han convertido en una referencia ampliamente utilizada para la evaluación de algoritmos de clasificación de modulaciones y otras aplicaciones académicas como el entrenamiento de un sistema de radar [1]. Estos datasets contienen señales de diferentes tipos de modulación y niveles de relación señal-ruido (SNR), permitiendo estudiar el comportamiento de diversos modelos de inteligencia artificial bajo condiciones variadas y cercanas a escenarios reales de transmisión. Particularmente, RadioML 2016 y RadioML 2018 ofrecen una amplia diversidad de modulaciones analógicas y digitales, lo que los convierte en una base adecuada para realizar análisis comparativos entre distintos enfoques de clasificación.

En este documento se desarrolló un estudio comparativo entre modelos basados en Machine Learning (ML) y Deep Learning (DL), utilizando datasets de Radio ML basados en señales medidas con diferentes modulaciones y relaciones señal a ruido (SNR). Para el enfoque de Machine Learning se implementaron los algoritmos K-Nearest Neighbors (KNN) y K-Means, evaluando el comportamiento mediante diferentes estrategias de procesamiento y validación. Por otro lado, se incorporaron técnicas de reducción de dimensionalidad como el Análisis de Componentes Principales (PCA), con el objetivo de disminuir la complejidad computacional y analizar el impacto de la transformación de características sobre la capacidad de clasificación de modelos. [2]

Por otra parte, en el enfoque de *Deep Learning* se emplearon arquitecturas basadas en Redes Neuronales Convolucionales (CNN) y Redes Neuronales Recurrentes (RNN). Las CNN permiten extraer automáticamente patrones espaciales relevantes presentes en las señales de fase y cuadratura (IQ), mientras que las RNN aprovechan la naturaleza secuencial de los datos para modelar dependencias temporales en las señales de comunicación. Estos modelos han demostrado un desempeño sobresaliente en tareas de clasificación complejas. [3]

El desarrollo de este trabajo busca aportar una visión comparativa y experimental sobre el uso de técnicas de inteligencia artificial en sistemas de comunicaciones inalámbricas, evidenciando cómo los métodos de aprendizaje automático y profundo pueden contribuir al diseño de sistemas más robustos, adaptativos e inteligentes para el reconocimiento automático de modulaciones.

Este documento se divide en los siguientes apartados, en la primera sección se encuentra la **identificación del problema**, allí se abordan las necesidades a partir de las cuales surgió el desarrollo de este experimento, posterior a esto se encuentran los **objetivos** a los que los autores esperaban llegar una vez finalizado el documento, seguido está el **marco teórico** donde se plantean los conceptos requeridos para el entendimiento del documento y a su vez, los antecedentes en materia relacionada, se continua con una **metodología** donde se explica a detalle cómo se llevaron a cabo los diferentes algoritmos, y de esta metodología

surgen unos **resultados**, apartado donde se evidencia el comportamiento real de los algoritmos con los dos datasets de RadioML de manera gráfica y teórica, por último el documento cuenta con **conclusiones** por parte de los autores, donde resaltan los puntos más relevantes del experimento.

II. Identificación del Problema

El crecimiento exponencial de las comunicaciones inalámbricas y el aumento constante de dispositivos conectados han generado una alta demanda del espectro radioeléctrico. Sin embargo, aunque las bandas de frecuencias son asignadas a operadores o portadores específicos, en muchos casos estas no son utilizadas en su totalidad de manera continua, produciendo periodos que no se utiliza el espectro, esto provoca ineficiencias en el aprovechamiento de un recurso limitado y de gran importancia para las telecomunicaciones modernas. Es por ello que surge este experimento, identificar el tipo de modulación de manera automática es fundamental en las telecomunicaciones modernas dado que mejora la precisión frente a los métodos manuales, es decir, en un sistema convencional el transmisor y el receptor se ponen de acuerdo sobre qué modulación van a usar, por otro lado, con clasificación automática el receptor se vuelve inteligente y puede saber el tipo de modulación y prepararse para demodularla sin tener información por parte del transmisor. [4]

Uno de los principales desafíos en los sistemas de comunicación actuales consiste en identificar de manera automática cuándo una banda o canal presenta espacios libres o niveles bajos de ocupación, permitiendo que otros usuarios o sistemas puedan aprovechar temporalmente dichos recursos sin generar interferencias. [5]

Por lo tanto, este trabajo busca estudiar y comparar diferentes modelos de inteligencia artificial aplicados a la clasificación automática de modulaciones, con el fin de analizar su desempeño y su potencial en la aplicación de sistemas de aprovechamiento eficiente del espectro.

III. Objetivos

A) **Objetivo General**

Desarrollar modelos de Machine Learning y Deep Learning para el reconocimiento automático de modulaciones utilizando los datasets RadioML 2016 y RadioML 2018.

B) **Objetivos Específicos**

a) Implementar algoritmos de *Machine Learning* y *Deep Learning*, específicamente K-Means, KNN, CNN y RNN, para la clasificación automática de modulaciones presentes en señales de radiofrecuencia.

b) Evaluar el desempeño y aplicación de los modelos en el aprovechamiento eficiente del espectro radioeléctrico.

c) Comparar el comportamiento de los diferentes modelos mediante métricas de desempeño y análisis de clasificación.

IV. Marco Teórico

a) Modulaciones:

La modulación es un proceso que permite modificar una señal portadora para transmitir información, variando las propiedades de la onda portadora como su amplitud, fase o frecuencia. Existen dos tipos de modulaciones dependiendo la naturaleza de la modulante las cuales son analógicas y digitales, dentro de estas se despliegan muchas más modulaciones que son usadas dependiendo los requerimientos de la transmisión.

- **Modulaciones Analógicas**: La modulación analógica implica modificar una señal análoga para transmitir información a través de un canal de comunicación, en esta se modifican parámetros de la onda portadora de manera continúa para representar la información. Es usada debido a la simplicidad de su diseño y buena calidad de señal para audio y video, sin embargo esta es bastante susceptible al ruido e interferencias.

  Existen dos tipos principales de modulación analógica: Modulación por Amplitud (AM) donde se varía la amplitud de la portadora con base a la señal de información,y Modulación de Frecuencia (FM) donde la frecuencia de la portadora se ajusta de acuerdo con la señal de información. De las dos anteriores existen variaciones, estas variaciones son algunas de las que están presentes en ambos datasets [6].

  AM-DSB: Modulación por amplitud en doble banda lateral.
  AM-SSB: Modulación por amplitud en banda lateral única.
  WBFM: Modulación de frecuencia de banda ancha.

- **Modulaciones Digitales**: Es el proceso mediante el cual una señal portadora modifica algunas de sus propiedades para transportar información binaria de un punto a otro. Lo que distingue la modulación digital es su carácter discreto, es decir que los cambios ocurren en valores definidos y finitos, dándole mayor robustez frente al ruido y la interferencia, a su vez ofrece alta eficiencia espectral. Una de sus mayores ventajas es que la señal puede recuperarse por completo mediante repetidores eliminando la acumulación de ruido [7].

Las principales técnicas de modulación digital que se pueden encontrar en los datasets son las siguientes:

ASK: Modulación por desplazamiento de amplitud.

PSK: Modulación por desplazamiento de fase.

QAM: Modulación de amplitud en cuadratura.

FSK: Modulación por desplazamiento de frecuencia.

QPSK: Modulación por desplazamiento de fase en cuadratura.

De las anteriores se desprenden otras combinaciones que también son usadas en ambos datasets. Sin embargo, las diferencias entre estas modulaciones son mínimas dado que cada una se adapta a condiciones distintas de transmisión, ruido y eficiencia espectral según el sistema de telecomunicaciones que se use, generalmente solo cambian parámetros específicos como el número de símbolos, el tamaño de la constelación, la tasa de codificación u otras configuraciones particulares de la señal. [7]

b) Dataset:

Un dataset es un conjunto de datos organizado que se estructura por lo general en filas y columnas, se pueden presentar en diferentes formatos como CSV, JSON, XML, entre otros. En este caso se usaron dos datasets creados por Deepsig Inc, el RadioML 2016 en formato pickle, el cual es un archivo que almacena objetos de python convertidos en una secuencia de bytes mediante el proceso de serialización y el RadioML 2018 en formato HDF5 que es un formato de archivo jerárquico y de código abierto diseñado para almacenar y organizar grandes volúmenes de datos complejos junto con sus metadatos, los cuales fueron creados con la finalidad de que se usaran como experimentación ya que incluyen conjunto de datos tanto de efectos sintéticos simulados de canales como grabaciones por aire de diferentes tipos de modulación digital y analógica, que han sido fuertemente validados [8]. La siguiente imagen ilustra las diferencias entre ambos datasets usados:

Cuadro I
COMPARACIÓN ENTRE LOS DATASETS RADIOML 2016.10A Y RADIOML 2018.01A.
AUTOR: DEEPSIGN

Característica	**RadioML 2016.10a**	**RadioML 2018 01A**
Complejidad	Baja / Introductoria	Alta / Realista
Número de Modulaciones	11 clases	24 clases
Longitud de Muestra	128 muestras complejas (I/Q)	1024 muestras complejas (I/Q)
Formato de Datos	I/Q (2×128)	I/Q (1024×2)
Rango de SNR	-20 dB a $+18$ dB (pasos de 2 dB)	-20 dB a $+30$ dB (pasos de 2 dB)
Total de Ejemplos	$\sim$220,000	$\sim$2,555,904 (más de 2.5 millones)
Formato de Archivo	.pkl (Python Pickle)	.h5 (HDF5 Hierarchical Data Format)
Origen de la Señal	Sintético (GNU Radio puro)	Sintético + grabaciones Over-the-Air (OTA)
Efectos del Canal	Ruido Gaussiano (AWGN), fading ligero, desviación de reloj simple	Fading multitrayecto realista, desviación de oscilador local (LO), ruido impulsivo

c) Relación Señal a Ruido (SNR):

La SNR es una medida utilizada para comparar la intensidad de una señal útil frente al ruido no deseado que la acompaña. Una SNR alta indica que la señal predomina sobre el ruido y viceversa para una SNR baja. Para el caso de los RadioML, estos poseen diferentes tipos de SNR que van desde -20dB hasta los 18dB o 30dB, por lo tanto, durante la experimentación se variaban los SNR con la finalidad de descubrir cuál brindaba una precisión mayor. En el ámbito de las telecomunicaciones se considera que una SNR de 10dB proporciona una buena calidad de recepción dado que se considera un nivel óptimo para la ganancia de antenas contribuyendo así a una mejor calidad de recepción al equilibrar la potencia de la señal y el ruido de fondo, por lo tanto, es un estándar comunmente usado en la industria [9].

d) Machine Learning:

El ML consiste en desarrollar algoritmos que identifican patrones en los datos y utilizan esa información para hacer predicciones o tomar decisiones de manera autónoma. Este funciona a través de lógica matemática, se introduce un algoritmo matemático que aprenda a asignar una entrada determinada a la salida esperada [10]. En este documento se usaron dos algoritmos de ML: KNN y K-Means.

- **K-Nearest Neighbors:** Es un método de aprendizaje supervisado usado tanto para clasificación como para regresión. Es no paramétrico (no asume una forma

específica para la función que modela los datos), emplea la proximidad para realizar clasificaciones o predicciones sobre la agrupación de un punto de datos individual. La etiqueta de clase se asigna por mayoría de votos, es decir, se emplea la etiqueta que se representa con más frecuencia en torno a un punto de datos determinado, es uno de los primeros algoritmos que se aprenden en la ciencia de datos debido a su sencillez y precisión. Sin embargo, a medida que un conjunto de datos crece, KNN se vuelve cada vez más ineficaz, comprometiendo el rendimiento general del modelo.

KNN tiene algunos requisitos para su funcionamiento, para determinar qué puntos de datos están más cerca de un punto de consulta determinado, será necesario calcular la distancia entre el punto de consulta y los demás puntos de datos. Esas métricas de distancia ayudan a formar límites de decisión, que dividen los puntos de consulta en diferentes regiones, se pueden manejar diferentes tipos de distancia, como la euclidiana, manhattan, y/o hamming, a su vez, se debe definir un valor de K, que define cuántos vecinos se verificarán para determinar la clasificación de un punto de consulta específico. Los valores más bajos de k pueden tener una varianza alta, pero un sesgo bajo, y los valores más grandes de k pueden conducir a un sesgo alto y una varianza más baja.

Las ventajas de este algoritmo consisten en que es fácil de aplicar, también se adapta fácilmente y requiere de pocos hiperparámetros, por otro lado, sus desventajas se basan en que este es no escalable, ocupa más memoria y almacenamiento de datos, y a su vez, no funciona bien con entradas de datos de alta dimensión [11]. En la Figura 1 se puede apreciar el funcionamiento de KNN, donde se tenía un punto de referencia entre dos clases, donde al final el punto eligió la clase B dado que era la que tenía más puntos de referencia cerca.

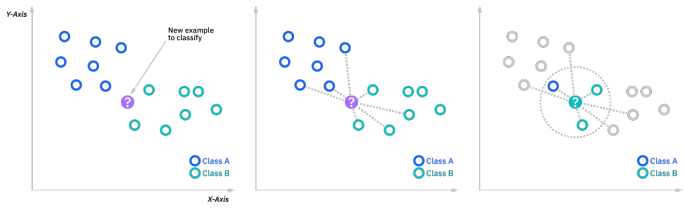


Figura 1. Ejemplo de KNN. Tomada de: Profesorsnake

- **K-Means:** El algoritmo K-Means es un método de agrupamiento que divide un conjunto de datos en K grupos o clusters. Los datos se agrupan de tal manera que los puntos en el mismo clúster sean más similares entre sí que los puntos en otros clusters, con el algoritmo K-Means es posible recopilar grandes cantidades de información similar en un mismo lugar, hecho que ayuda a encontrar patrones y hacer predicciones en grandes conjuntos de datos. Para utilizar el algoritmo K-Means, primero se especifica el número de clusters deseados (k). Por ejemplo, al establecer k = 2, su conjunto de datos se agrupará en 2 grupos, cada grupo está representado por su centro o centroide, que corresponde a la media aritmética de los puntos de datos asignados al grupo. De esta manera, el algoritmo funciona a través de un proceso iterativo hasta que cada punto de datos está más cerca del centroide de su propio grupo que de los centroides de otros grupos, minimizando la distancia dentro del grupo en cada paso.

  Sus ventajas consisten en la simplicidad de uso, buena convergencia y flexibilidad, sus desventajas se basan en la sensibilidad de la elección del k, este tampoco aprende fronteras supervisadas y el algoritmo puede no generalizar bien cuando los clústeres tienen tamaños o densidades muy distintas [12]. En la Figura 2 se puede apreciar la lógica que se aplica en k-means, allí se tenían diversos datos dispersos, pero una vez aplicado el algoritmo estos datos se dividieron en dos grupos, dado que era la cantidad de clusters.

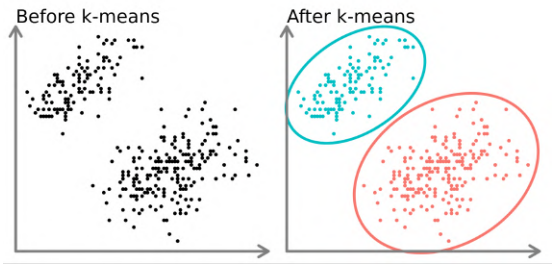


Figura 2. Ejemplo de K-Means. Tomada de: Projectscybersummit

e) Deep Learning:

El deep learning es un subconjunto de machine learning impulsado por redes neuronales cuyo diseño se inspira en la estructura del cerebro humano, las redes neuronales de los modelos de deep learning comprenden muchas capas interconectadas de “neuronas” que realizan cada una una operación matemática, mediante el uso de Machine Learning para ajustar la fuerza de las conexiones entre las neuronas individuales de las capas adyacentes (es decir, los pesos y sesgos variables del modelo), la red puede optimizarse para obtener outputs más precisos. Los modelos de deep learning suelen entrenarse mediante el aprendizaje supervisado en datos etiquetados para realizar tareas de regresión y clasificación.

En comparación con las técnicas clásicas de machine learning, el deep learning requiere una

cantidad extremadamente grande de datos y recursos computacionales para el entrenamiento [13]. Se usaron dos modelos de DL: CNN y RNN.

- **CNN:** Es un tipo especializado de algoritmo de aprendizaje profundo, se distingue por su capacidad para extraer características de forma autónoma a gran escala, evitando la necesidad de ingeniería manual de características y mejorando así la eficiencia. Las capas convolucionales confieren a las CNN sus características de invariabilidad traslacional, lo que les permite identificar y extraer patrones y características de los datos independientemente de las variaciones de posición, orientación, escala o traslación. Un problema de CNN es el sobre ajuste que ocurre cuando el modelo aprende demasiado bien los datos de entrenamiento ("aprendizaje de memoria"), incluidos su ruido y sus valores atípicos. Un aprendizaje de este tipo conduce a un modelo que funciona bien con los datos de entrenamiento, pero mal con nuevos datos no vistos [14].

  En la Figura 3 se tiene un proceso de convolución, donde se tienen capas primerizas pero también pueden haber capas de pooling, en las primeras capas se aplican los filtros para reconocer las características de los pixeles individuales, en las capas de pooling se reduce el tamaño de los mapas de características y las abstraen, finalmente en el fully connected flyer se forma la última capa, la cual produce la imagen final.

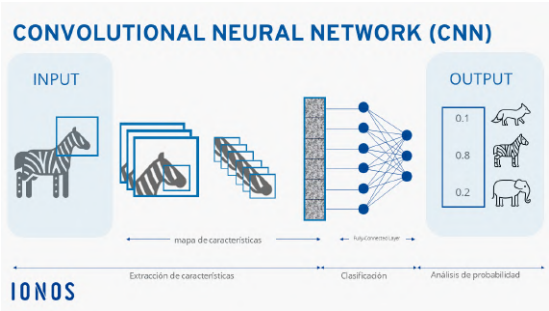


Figura 3. Ejemplo de CNN. Tomada de: IONOS Digital Guide

- **RNN:** Las RNN recuerdan entradas pasadas gracias a una memoria interna que es útil para predecir los precios de las acciones y generar texto, transcripciones y traducción automática, la salida en la RNN depende de elementos anteriores dentro de la secuencia. Las redes recurrentes también comparten parámetros y los mismos pesos en todas las capas de la red y durante el descenso del gradiente, los pesos y la base se ajustan individualmente para reducir la pérdida.

  Las limitaciones de RNN consisten en el desvaneci-miento de gradiente que se produce cuando el gradiente se hace tan pequeño que la actualización de los parámetros se vuelve insignificante; finalmente, el algoritmo deja de aprender. También cuando el gradiente se hace demasiado grande, que se acumulan gradientes de error mayores, y los pesos del modelo se hacen demasiado grandes. Este problema puede provocar tiempos de entrenamiento más largos y un rendimiento deficiente del modelo [15]. En la Figura 4 se evidencia que RNN está formado por neuronas, estas se organizan en capas de entrada, salidas y ocultas. La capa de entrada recibe la información para procesar y la capa de salida proporciona el resultado. El procesamiento, el análisis y la predicción de los datos se llevan a cabo en la capa oculta.

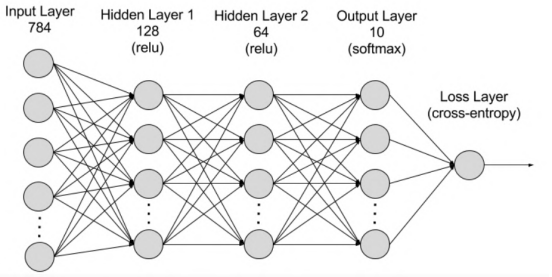


Figura 4. Ejemplo de RNN. Tomada de: AWSD

V. Antecedentes

El reconocimiento automático de modulaciones (AMC) ha sido objeto de estudio creciente en la última década, motivado por la necesidad de gestionar de forma eficiente el espectro radioeléctrico en entornos de comunicaciones cada vez más densos y heterogéneos.

En el trabajo de Maguana Zhindón y Reino Criollo [16] titulado *"Modulación adaptativa para un sistema OFDM, utilizando técnicas de Machine Learning"* (Universidad de Cuenca, 2024), se implementó un sistema OFDM adaptativo que ajusta dinámicamente el esquema de modulación en función de las condiciones del canal. Para ello se entrenaron tres modelos de ML supervisado: regresión lineal robusta, árbol de decisión y K-Nearest Neighbors (KNN), evaluando su rendimiento en términos del BER y el trhroughput sobre cinco esquemas de modulación (QPSK, 8-PSK, 16-QAM, 32-QAM, 64-QAM) utilizando diferentes valores de SNR. Los resultados demostraron que los modelos de clasificación *KNN y árbol de decisión* superan a la regresión lineal en precisión de predicción, logrando un BER inferior a 0.001 con un SNR de 17 dB o más. Este trabajo evidencia la viabilidad del uso de KNN como técnica de clasificación de modulaciones en sistemas adaptativos y establece una referencia directa para el enfoque de Machine Learning desarrollado en el presente documento.

Por otro lado, Mosquera Trujillo [17] en su tesis de maestría *"Automatic Modulation Classification for Software Defined Radios: A Deep Learning Approach"* (Universidad Nacional de Colombia, 2025) abordó los tres principales desafíos que limitan el despliegue práctico de modelos de Deep Learning para AMC: la baja robustez ante condiciones dinámicas del canal, la falta de interpretabilidad de los modelos y la elevada complejidad computacional. Como solución, propuso una arquitectura ligera denominada *ComplexMobileNet-AMC*, que integra convoluciones de valores complejos, bloques separables en profundidad y mecanismos de auto-atención, junto con una etapa de preprocesamiento adaptativo basado en *Random Fourier Features* (RFF) y una estrategia de aumento de datos consciente de la modulación.

Los experimentos realizados sobre el dataset RadioML 2016 demostraron que el modelo propuesto supera a arquitecturas de referencia como CNN puras, modelos basados en LSTM y enfoques híbridos CNN-RNN, tanto en eficiencia computacional (menor número de parámetros y tiempo de inferencia reducido) como en precisión de clasificación, especialmente en escenarios de bajo SNR (por debajo de 10 dB). Este trabajo establece un punto de referencia relevante para el enfoque de Deep Learning explorado en el presente documento, particularmente en lo que respecta al uso del dataset RadioML y la comparación entre arquitecturas CNN, RNN y modelos híbridos.

Asimismo, O'Shea, Roy y Clancy [18] en su artículo "Over-the-Air Deep Learning Based Radio Signal Classification" (IEEE Journal of Selected Topics in Signal Proccessing, 2018) realizaron un estudio comparativo exhaustivo entre métodos clásicos basados en estadísticas de orden superior y enfoques de Deep Learning para la clasificación de señales de radio.

Como método de referencia emplearon momentos de orden superior (HOM) y cumulantes (HOC) combinados con un clasificador de arboles de gradiente potenciado (XGBoost), mientras que como modelos de aprendizaje profundo evaluaron una red neuronal convolucional (CNN) adaptada de la arquitectura VGG y una red residual profunda (ResNet).

Los experimentos se realizaron sobre un dataset propio de 24 esquemas de modulación analógicos y digitales, denominado RadioML, evaluado tanto en canales simulados con distintos niveles de desvanecimiento y offset de frecuencia portadora, como en transmisiones reales sobre el aire (OTA) utilizando radios definidas por software USRP B210. Los resultados mostraron que la ResNet alcanzó una precisión del 99.8 % en el conjunto de 11 modulaciones bajo AWGN, y del 95.6 % en el dataset OTA de 24 clases, superando consistentemente a la CNN VGG en aproximadamente 5 dB de sensibilidad y logrando una ventaja de hasta 6 dB frente al método de referencia bajo condiciones de desvanecimiento.

Adicionalmente, los autores exploraron el aprendizaje por transferencia (transfer learning) desde datos sintéticos hacia mediciones OTA, obteniendo una pérdida de precisión de apenas el 7 % sin re entrenamiento, recuperable parcialmente mediante ajuste fino de las últimas capas densas. Este trabajo constituye una referencia fundamental para el presente informe, tanto por el uso del dataset RadioML como por el análisis sistemático del impacto de parámetros como el tamaño del conjunto de entrenamiento, la profundidad del modelo y las condiciones del canal sobre el desempeño de los clasificadores basados en Deep Learning.

Finalmente, Martínez-Quintero et al. [19] en el artículo *"Design and Implementation of a Digital Modulation Classification System Using Intelligent Algorithms"* (Visión Electrónica, 2023) propusieron un sistema de clasificación de modulaciones digitales basado en la red neuronal convolucional InceptionResNetV2, entrenada con imagenes de diagramas de constelación generados en GNURadio y procesado en Matlab. El dataset propio, compuesto por 1377 imágenes de entrenamiento y 462 de prueba para seis esquemas de modulación (BPSK, QPSK, 8PSK, 16QAM, 32QAM y 64QAM), permitió alcanzar una precisión general de 81.81 %. Este informe es relevante porque ilustra las limitaciones de las CNN frente a modulaciones de orden superior como 32QAM y 64QAM.

VI. Metodología

La metodología en este trabajo fue desarrollada en el entorno de programación Google Colaboratory (Google Colab), aprovechando sus capacidades de procesamiento en la nube y su compatibilidad con bibliotecas especializadas para análisis de datos, aprendizaje automático y visualización. Se implementaron modelos de Machine Learning (K-Means y KNN) y Deep Learning (CNN y RNN) para la clasificación automática de modulaciones sobre los datasets RadioML 2016 y RadioML 2018. En esta sección se describe el procedimiento seguido para cada modelo, comenzando por el dataset RadioML 2016.

El dataset RadioML 2016 (RML2016.10a) fue creado por Deepsig Inc. y se distribuye en formato `.pkl` (pickle de Python). Su estructura interna es un diccionario donde cada entrada está indexada por una tupla `(moluación, SNR)` por ejemplo `('QPSK', 10)` o `('AM-DSB', -6)`.

Para cada combinación de modulación y SNR, el diccionario almacena un arreglo de forma $N \times 128$, donde N es el número de muestras, el eje de tamaño 2 corresponde a las componenetes en fase (I) y cuadratura (Q) de la señal, y 128 es la longitud temporal de cada muestra. En total el dataset contiene 11 tipos de modulación (8 digitales y 3 analógicas) y 20 niveles de SNR que van desde -20 dB hasta 18 dB en pasos de 2 dB. Para todos los modelos implementados sobre este dataset se trabajó extrayendo las

componentes I y Q de cada señal.

El dataset RadioML 2018.01A introduce modulaciones de orden superior mucho más difíciles de distinguir, lo que obliga a la red neuronal a aprender características más sutiles.

Sus nuevas inclusiones: 32PSK, 16APSK a 128APSK, y QAM de alto orden (128QAM, 256QAM). Distinguir entre una 64QAM y una 128QAM con ruido es un reto significativo que la versión 2016 no tiene.

A) **KNN**

KNN utiliza las etiquetas reales durante el entrenamiento, lo que le permite aprender fronteras de decisión más precisas. La distancia entre muestras se ponderó de forma inversamente proporcional a la distancia (`weights='distance'`), dando mayor influencia a los vecinos más cercanos.

Se obtuvieron 8 atributos estadísticos de los datos como la media, varianza, asimetría (skewness) y curtosis de la amplitud y de la fase. Estas características sintetizan el comportamiento estadístico de la señal en el dominio del tiempo de forma eficiente para el clasificador basado en distancias.

Dado que KNN es sensible a la escala de los datos (una característica con mayor magnitud dominaría el cálculo de distancias), se aplicó un Escalador Estándar que centra cada característica en media cero y la normaliza a varianza unitaria.

Se dividió el conjunto de datos en 70 % entrenamiento y 30 % prueba. Tras evaluar diferentes valores de k, se seleccionó $k = 11$ como el que produce mejor balance entre sesgo y varianza para este conjunto de datos.

Una vez entrenado el modelo, se evaluó su exactitud de forma independiente para cada uno de los 20 niveles de SNR del dataset, construyendo una curva de desempeño que permite visualizar el comportamiento del clasificador desde condiciones de muy bajo SNR (-20 dB) hasta condiciones favorables (18 db).

En la Figura 5 se observa el diagrama de flujo del algoritmo implementado para el entrenamiento del modelo KNN.

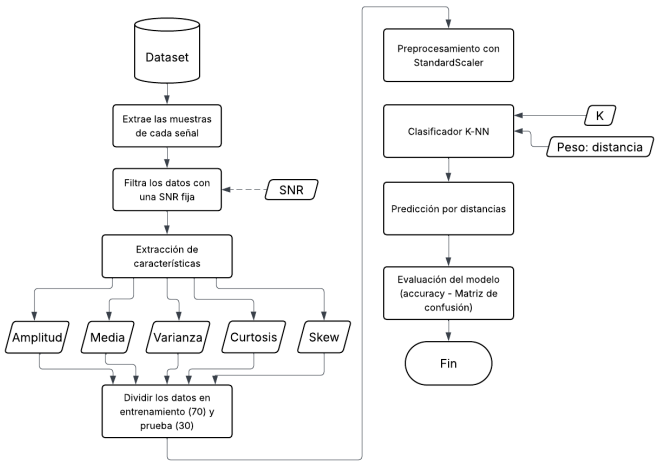


Figura 5. Estructura del Modelo KNN. Fuente: Autores

B) **K-Means**

Dado que K-Means no aprende etiquetas durante el entrenamiento, una vez obtenidos los clústeres se etiqueta cada uno con la modulación más frecuente entre las muestras que contiene (mapeo por moda), permitiendo así evaluar su desempeño como clasificador. La implementación se estructuro en primer lugar cargando del archivo `RML2016.10a_dict.pkl` desde Google Drive. Para este y otros experimentos se trabajó con un SNR fijo de 18 dB, esto ya que era la SNR más alta presente en el dataset, por ende, aunque 10 dB sea el estándar, con finalidades de aumentar la precisión y ofrecer las condiciones de señal más favorables del dataset para evaluar el desempeño máximo alcanzable por el modelo, se trabajó con el más alto para todos los algoritmos.

Dado que K-Means opera sobre vectores de características y no directamente en señales crudas, se construyó un descriptor (se dividieron los datos en diferentes características) de 38 atributos por señal. Estos atributos se dividen en 4 grupos:

- **Características Temporales (10):** Capturan propiedades estadísticas de los componentes I y Q en el dominio del tiempo, incluyendo desviación estándar, asimetría (*skewness*), curtosis y variaciones en la envolvente de amplitud.

- **Características de Fase (8):** Describen el comportamiento de la fase instantánea de la señal y su derivada (frecuencia instantánea), incluyendo su dispersión, la proporción de saltos abruptos y la varianza de la aceleración de fase. Permiten separar modulaciones con constelaciones bien definidas.

- **Características Frecuenciales (12):** Obtenidas mediante la Transformada Rápida de Fourier (FFT) y la densidad espectral de potencia (PSD) estimada con el método de Welch. Son fundamentales para clasificar modulaciones analógicas.

- **Características de Constelación (8):** Analizan la distribución de puntos en el plano I/Q mediante métricas como la entropía de los niveles de amplitud, la varianza de cuadrantes y la correlación entre I y Q. Resultan esenciales para distinguir modulaciones de orden superior.

Luego de dividir los datos, las características fueron normalizadas con Escalador Robusto, y se evaluaron con dos estrategias. La primera fue el Análisis de Componentes Principales (PCA), que proyecta los datos sobre las direcciones de mayor varianza conservando la mayor parte de la información con menor dimensionalidad. La segunda fue UMAP (Uniform Manifold Approximation and Projection), una técnica que preserva la estructura no lineal de los datos.

El desempeño de cada configuración se evaluó mediante validación cruzada con 5 particiones. Para cada estrategia implementada se obtuvo la métrica principal denominada como *accuracy*.

En la Figura 6 se observa el diagrama de flujo del algoritmo implementado para el entrenamiento del modelo K-Means.

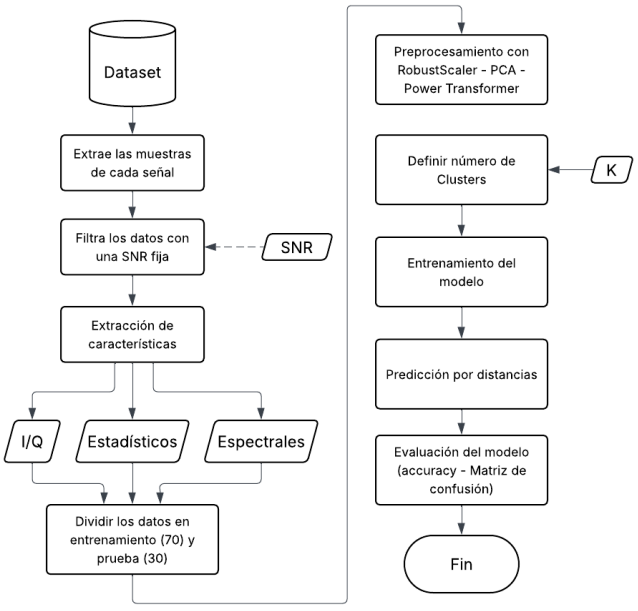


Figura 6. Estructura del Modelo K-Means. Fuente: Autores

C) **CNN**

Las Redes Neuronales Convolucionales (CNN) son arquitecturas de Deep Learning diseñadas para extraer automáticamente patrones locales en los datos mediante filtros Convolucionales. En el contexto de señales I/Q, las capas aprenden a detectar patrones temporales relevantes directamente desde la señal cruda, sin necesidad de construcción manual de características. Para este trabajo se implementó una arquitectura CNN basada en bloques residuales (ResNet), que introduce conexiones de atajo (skip connections) entre capas para facilitar el flujo del gradiente durante el entrenamiento y permitir redes mas profundas sin degradación del desempeño.

Para este modelo se trabajó unicamente con un SNR de 18 dB. El modelo está compuesto por las siguientes etapas:

- **Capa de Entrada:** Una convolución de 1 dimensión de 64 filtros con Kernel de tamaño 7, seguida de normalización por intervalos (lotes) y activación ReLU. Esta capa inicial detecta patrones de baja complejidad en la señal en el dominio del tiempo.

- **Bloques Residuales:** Tres pilas residuales progresivamente mas profundas. Cada bloque aplica dos convoluciones de 1 dimensión con normalización por intervalos, y suma su salida a la entrada original a través de una conexión de atajo (con una convolución 1×1 para ajustar dimensiones). Esto permite que el modelo aprenda correcciones sobre la señal de entrada en lugar de transformaciones completas, facilitando el entrenamiento profundo. Los tres bloques utilizan 64, 128 y 256 filtros respectivamente, con submuestreo por *MaxPooling* entre los dos primeros para reducir la dimensionalidad temporal.

- **Cabeza clasificadora:** Una capa *GlobalAveragePooling1D* que colapsa la dimensión temporal promediando los mapas de características, seguida de una capa densa de 128 neuronas con ReLU, una capa *Dropout* del 40 % para regularización, y una capa de salida *softmax* para las 11 clases de modulación.

  El modelo fue compilado con el optimizador Adam con tasa de aprendizaje inicial de 10^{-3} y función de pérdida *sparse categorical crossentropy*.

  Los datos se dividieron en 80 % entrenamiento y 20 % prueba con estratificación por clase. Del conjunto de entrenamiento se reservó un 15 % adicional para validación interna. Se emplearon dos *callbacks*:*ReduceLROnPlateau*, que reduce la tasa de aprendizaje a la mitad si la pérdida de validación no

mejora en 5 épocas consecutivas (con un mínimo de 10^{-6}), y *EarlyStopping*, que detiene el entrenamiento si la exactitud de validación no mejora en 15 épocas y restaura los mejores pesos encontrados. El entrenamiento se realizó por un máximo de 100 épocas con un tamaño de lote de 128 muestras.

En la Figura 7 se observan las capas y neuronas utilizadas para entrenar el modelo.

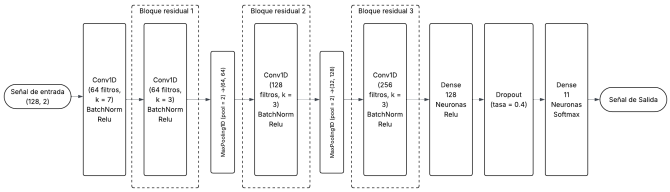


Figura 7. Capas Modelo CNN. Fuente: Autores

D) **RNN**

A diferencia de KNN y K-Means, que operan sobre vectores de características estáticas, una RNN recibe la señal como una secuencia de muestras en el tiempo y aprende patrones dinámicos a lo largo de ella. Para este trabajo se implementó una arquitectura de tipo *Dual-Stream*, que procesa simultáneamente dos representaciones complementarias de la señal con el fin de capturar tanto la información de amplitud como la de fase y cuadratura.

Las señales, originalmente de forma $(N, 2, 128)$, se transpusieron a $(N, 128, 2)$ para que la dimensión temporal quedara en el eje de secuencia, tal como lo requieren las capas recurrentes. Posteriormente se normalizaron dividiendo cada señal por su valor absoluto máximo.

A partir de las componentes I y Q de cada señal se derivaron dos representaciones: Corriente de amplitud, formada por la envolvente de amplitud $A = \sqrt{I^2 + Q^2}$ y su gradiente temporal ∇A. Esta corriente captura variaciones en la potencia instantánea de la señal, lo que resulta especialmente útil para distinguir modulaciones con múltiples niveles de amplitud. y Corriente de Fase I/Q, formada por las componentes I, Q y la fase instantánea $\phi = \arctan 2(Q, I)$. Esta corriente captura la estructura angular de la constelación, siendo más informativa para modulaciones de fase.

El modelo *Dual-Stream* consta de dos ramas recurrentes paralelas que procesan cada corriente de forma independiente antes de fusionar su información:

- **Rama de amplitud:** Una capa GRU (*Gated Recurrent Unit*) de 64 unidades con salida de secuencia completa, seguida de una capa *GlobalMaxPooling* que retiene el valor máximo activado a lo largo de la secuencia.

- **Rama de fase:** Una capa GRU bidireccional (*Bidirectional GRU*) de 64 unidades, que procesa la secuencia tanto en sentido directo como inverso para capturar dependencias temporales en ambas direcciones, seguida de una capa *GlobalAveragePooling*.

Los datos se dividieron en 85 % entrenamiento y 15 % prueba con estratificación por clase, para evaluar la capacidad del modelo de de generalizar a datos no vistos y evitar el sobreajuste, el conjunto de entrenamiento se usó para ajustar el modelo (aprender relaciones y patrones en los datos), y el conjunto de prueba se empleó para evaluar el desempeño del modelo en datos independientes. Durante el entrenamiento se emplearon dos *callbacks*: *ReduceLROnPlateau*, que reduce la tasa de aprendizaje en un factor de 0.3 si la pérdida de validación no mejora en 4 épocas consecutivas, y *EarlyStopping*, que detiene el entrenamiento si la exactitud de validación no mejora en 12 épocas y restaura los mejores pesos encontrados. El entrenamiento se realizó por un máximo de 60 épocas con un tamaño de lote de 64 muestras.Las salidas de ambas ramas se concatenan y pasan por una capa densa de 128 neuronas con activación ReLU, una capa *Dropout* del 30 % para regularización, y finalmente una capa de salida con activación *softmax* para las 11 clases de modulación. El modelo se compiló con el optimizador Adam (tasa de aprendizaje inicial de 0.001) y la función de pérdida *sparse categorical crossentropy*.
En la Figura 8 se observan las capas y neuronas utilizadas para entrenar el modelo.

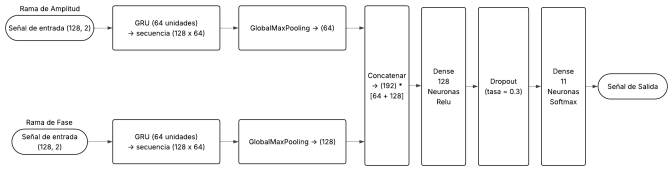


Figura 8. Capas Modelo RNN. Fuente: Autores

VII. Resultados

A) **RadioML 2016**

a) **KNN:** Se demostró que el rendimiento del algoritmo depende casi en su totalidad del pre-procesamiento aplicado. Transformadores como QuantileTransformer (para forzar normalidad) y técnicas supervisadas como LDA (Análisis Discriminante Lineal) fueron obligatorios para deformar el espacio geométrico

y permitir que la métrica de distancia (Manhattan) encontrara fronteras de decisión válidas. KNN tiene un techo de cristal en el dataset RML2016.10a, las confusiones presentes en la matriz entre clases físicamente similares, como QAM16 frente a QAM64, o las confusiones inducidas por silencios en señales analógicas (WBFM vs AM-DSB), generan solapamientos espaciales que ninguna métrica geométrica lineal puede separar sin la ayuda de extracción de características altamente no lineales. La extracción de características físicas avanzadas, específicamente la desviación y curtosis de la Fase desenrollada (unwrap) y la frecuencia instantánea, fueron los factores determinantes para estabilizar la clasificación de esquemas como PSK y FSK.

Se concluye que, aunque es un excelente modelo de referencia (baseline) para validar características extraídas, no es viable para la decodificación de radio cognitivo en tiempo real (SDR) donde se requieren latencias de milisegundos.

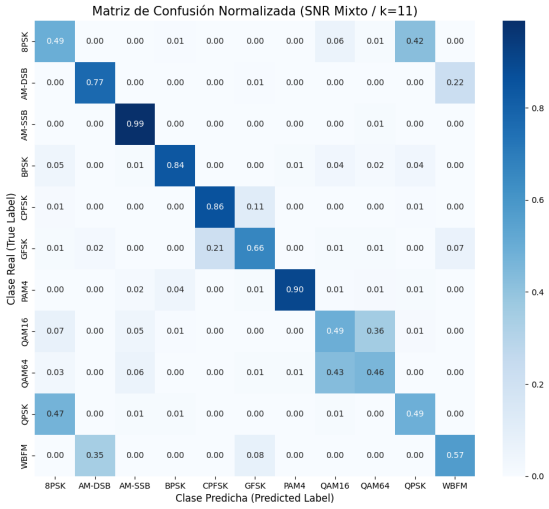


Figura 9. Matriz de Confusión KNN. Fuente: Autores

b) **K-Means**: La Figura 10 ilustra las cuatro familias de características extraídas y las modulaciones que cada una contribuye a separar.

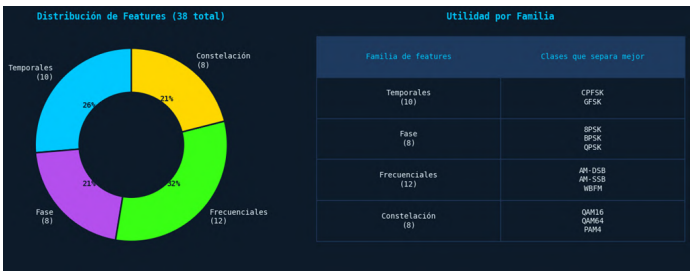


Figura 10. Características de K-Means. Fuente: Autores

La Figura 11 presenta la comparativa de accuracy entre todas las configuraciones evaluadas. Los resultados muestran que las configuraciones basadas en PCA con cualquier número de componentes no logran superar el baseline de referencia de 49 %, obteniendo únicamente un 18.20 % de accuracy. En contraste, las configuraciones que utilizan UMAP como técnica de reducción dimensional alcanzan valores superiores al 60 %, siendo la mejor configuración UMAP(15) con Ensemble la que logra el mayor desempeño con un 60.46 % de accuracy.

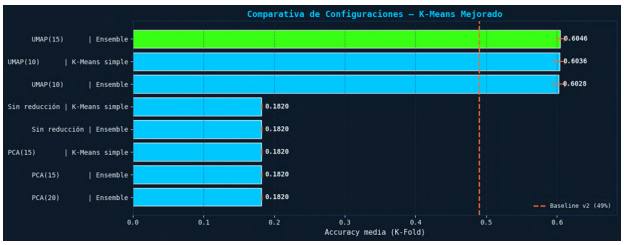


Figura 11. K-Means Comparativo. Fuente: Autores

El barrido de componentes PCA (Figura 12) confirma que esta técnica no mejora con mayor dimensionalidad, manteniéndose constante en 18.20 % en todo el rango evaluado, lo que indica que la estructura de los clústeres de modulación no es capturada adecuadamente por proyecciones lineales. Estos resultados evidencian una limitación fundamental de K-Means: al ser un método no supervisado, no aprovecha la información de las etiquetas durante el entrenamiento, lo que restringe su capacidad de discriminación frente a modulaciones con fronteras de decisión no lineales o muy próximas en el espacio de características.

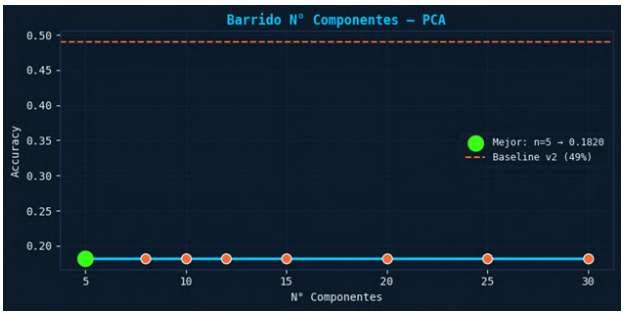


Figura 12. Barrido de Parámetros K-Means. Fuente: Autores

c) **CNN**: El archivo de audio original usado para modular estas señales contiene periodos de silencio. Sin voz ni música, una señal FM y una AM apagadas se ven exactamente iguales en el espectro (solo portadora), lo que hace que sea matemáticamente imposible para la CNN diferenciarlas en esos instantes, por ello en la matriz de confusión se puede ver que se confunde en estas, a su vez, como se ha mencionado anteriormente las constelaciones de QAM16 y QAM64 se solapan

debido al desvanecimiento del canal simulado. Para la red, discriminar entre ambas usando solo 128 muestras temporales es casi imposible.

También CNN trata los vectores de tiempo de los canales I y Q como si fueran coordenadas espaciales (píxeles de una imagen de una sola dimensión). La red no entiende el "tiempo", sino la geometría y los patrones de repetición de las transiciones de fase.

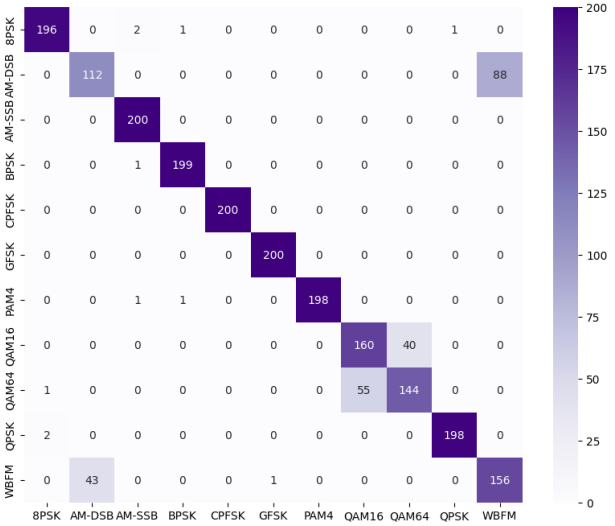


Figura 13. Matriz de Confusión. Fuente: Autores

d) **RNN:** La arquitectura Dual-Stream implementada procesa simultáneamente dos representaciones complementarias de la señal: una corriente de amplitud y una corriente de fase/IQ, fusionando su información antes de la clasificación final. Evaluada a SNR = 18 dB, la red alcanzó una exactitud de 89.00 %.

La matriz de confusión (Figura 14) revela que la arquitectura Dual-Stream logra una clasificación casi perfecta en la mayoría de las modulaciones. AM-SSB (300/300), CPFSK (300/300) y GFSK (300/300) son clasificadas con exactitud absoluta, lo que evidencia que la combinación de la corriente de fase instantánea con la corriente de amplitud proporciona representaciones suficientemente discriminantes para estos esquemas. AM-DSB (298/300), BPSK (296/300) y PAM4 (294/300) también presentan un desempeño sobresaliente, con errores mínimos y aislados.

El principal foco de confusión se concentra en dos pares de modulaciones. El primero es QAM16 y QAM64: de 300 muestras de QAM16, 230 se clasifican correctamente pero 58 son confundidas con QAM64 (19.3 % de error); de forma simétrica, de 300 muestras de QAM64, solo 220 se predicen correctamente mientras que 76 son confundidas con QAM16 (25.3 % de error). Esta confusión es estructural: ambas modulaciones pertenecen a la misma familia QAM y sus constelaciones comparten la misma geometría rectangular, diferenciándose únicamente en los bits por símbolo [20]. Con solo 128 muestras temporales y bajo condiciones de desvanecimiento del canal simulado, los niveles de amplitud de ambas constelaciones se solapan parcialmente, limitando la capacidad discriminante incluso de una red recurrente bidireccional.

El segundo foco de confusión involucra a WBFM: de 300 muestras, 179 se clasifican correctamente (59.7 %) y 121 son confundidas con AM-DSB (40.3 %). Este comportamiento reproduce el fenómeno observado en la CNN: cuando la señal de audio fuente contiene periodos de silencio, tanto la modulación FM de banda ancha como la AM de doble banda lateral presentan una envolvente prácticamente constante y un espectro similar al de una portadora sin modular, haciendo que sus representaciones en el espacio de características sean indistinguibles para el modelo. Adicionalmente, 8PSK presenta 14 confusiones con QPSK (4.7 %), lo que es consistente con la similitud angular de sus constelaciones cuando el ruido de fase desplaza los puntos de la constelación entre los sectores angulares adyacentes.

En términos comparativos, la RNN Dual-Stream obtiene un desempeño equivalente al de la CNN ResNet (89.23 %) y ligeramente inferior al KNN (90.49 %) a SNR = 18 dB, aunque con la ventaja de que la RNN modela explícitamente las dependencias temporales de la señal en lugar de tratarla como un patrón espacial estático. Las confusiones residuales en QAM16/QAM64 y WBFM/AM-DSB representan el límite inherente al dataset en este nivel de SNR, y no una limitación exclusiva de la arquitectura recurrente.

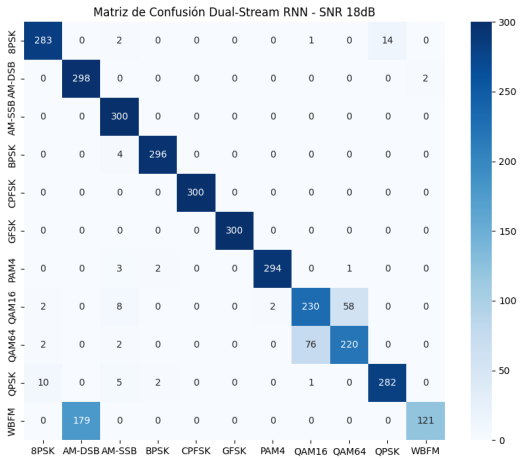


Figura 14. Matriz de Confusión RNN. Fuente: Autores

Los resultados muestran una clara brecha entre los modelos supervisados y el no supervisado. KNN alcanzó la mayor precisión con un 90.49 %, seguido muy de cerca por CNN (89.23 %) y RNN (89.00 %), lo que evidencia que los tres enfoques supervisados son comparablemente efectivos para la clasificación de modulaciones, con diferencias menores al 1.5 % entre ellos.

K-Means, al ser un algoritmo de agrupamiento no supervisado, obtuvo una precisión considerablemente inferior (60.10 %), lo cual era esperable dado que no se beneficia de etiquetas durante el entrenamiento. Esta diferencia de 30 puntos porcentuales respecto a los modelos supervisados indica que el problema de clasificación de modulaciones requiere información etiquetada para alcanzar un desempeño satisfactorio.

En definitiva, si el objetivo es maximizar la precisión, KNN resulta ser la opción más eficiente, ofreciendo el mejor rendimiento con menor complejidad computacional que los modelos de aprendizaje profundo (CNN, RNN).

Cuadro II
PRECISIÓN DE LAS MODULACIONES

Modulación	Precisión
KNN	90.49 %
K-Means	60.10 %
CNN	89.23 %
RNN	89.00 %

RadioML 2018

a) **KNN** Para el dataset RadioML 2018, que contiene 24 tipos de modulación, se implementó una versión más robusta del clasificador KNN combinada con Análisis Discriminante Lineal (LDA) como etapa previa de reducción dimensional supervisada. A diferencia del enfoque aplicado en RadioML 2016, aquí el LDA resulta indispensable: al proyectar los datos sobre las direcciones que maximizan la separación entre las 24 clases, transforma un espacio de características de alta dimensión en una representación donde la métrica de distancia de KNN puede operar de forma efectiva. Sin esta etapa, las métrica geométrica estándar logra separarlas.

El barrido de hiperparámetros Figuras 15, 16 y 17 evaluó sistemáticamente el número de vecinos k (de 1 a 63), la métrica de distancia (minkowski, euclidiana, manhattan, chebyshev, coseno y correlación) y la ponderación de votos (uniforme y por distancia). La configuración óptima encontrada fue $k = 59$, métrica coseno y ponderación por distancia, alcanzando una exactitud de 79.64 % a SNR = 30 dB. El uso de la métrica coseno, en lugar de la euclidiana tradicional, es significativo: en espacios de alta dimensión la distancia coseno mide la orientación angular entre vectores en lugar de su magnitud absoluta, siendo más robusta cuando las señales de distintas modulaciones tienen energías variables. El valor elevado de $k = 59$ indica que el modelo necesita consultar un vecindario muy amplio para tomar decisiones estables, lo cual es una consecuencia directa de la alta densidad de clases similares en el espacio de características.

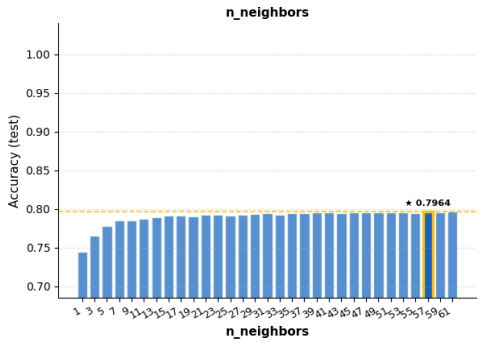


Figura 15. Barrido de Parámetros KNN. Fuente: Autores

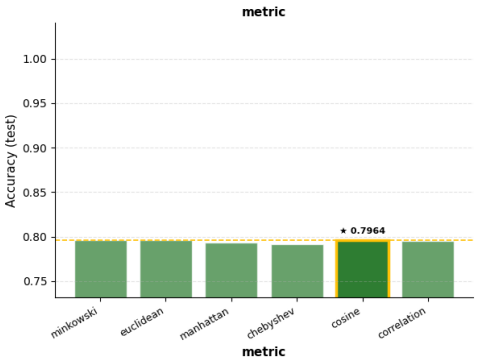


Figura 16. Barrido de Parámetros KNN. Fuente: Autores

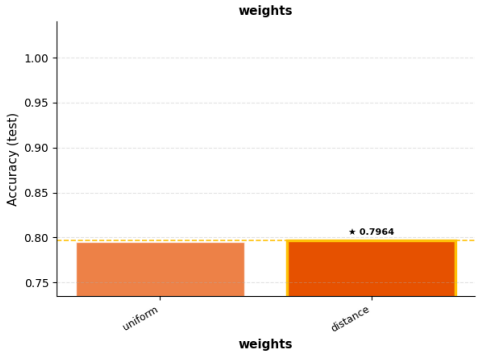


Figura 17. Barrido de Parámetros KNN. Fuente: Autores

La matriz de confusión Figura 18 revela un comportamiento claramente polarizado entre dos grupos de modulaciones. El primer grupo, compuesto por modulaciones con estructuras de constelación bien diferenciadas, es clasificado con precisión muy alta: OOK (100 %), BPSK (100 %), QPSK (100 %), FM (100 %), GMSK (100 %), OQPSK (100 %), 16APSK (98.7 %), 32APSK (98.3 %), 4ASK (96.5 %), 8PSK (96 %), 16QAM (95.8 %) y AM-SSB-WC (94 %). Estas modulaciones poseen características espectrales o de constelación lo suficientemente distintas como para que el clasificador basado en distancias las separe sin ambigüedad incluso con un descriptor compacto.

El segundo grupo, en cambio, presenta confusiones sistemáticas que revelan los límites estructurales del KNN.

Las modulaciones de orden superior de la familia PSK muestran solapamiento severo: 16PSK es clasificada correctamente solo el 44.6 % de las veces, confundiéndose con 32PSK (43 %) e incluso con 8PSK (12.3 %); de forma análoga, 32PSK alcanza apenas el 46.1 % de acierto, siendo confundida mayoritariamente con 16PSK (42.1 %).

Esto ocurre porque al aumentar el orden de la modulación PSK, los puntos de la constelación se acercan angularmente entre sí y sus diferencias en el espacio de características se vuelven imperceptibles para una métrica de distancia. Un comportamiento similar se observa en la familia QAM de alto orden: 64QAM (56.7 %), 128APSK (68.5 %), 128QAM (38 %), 64QAM (48.5 %) y 256QAM (37.2 %) muestran confusiones mutuas importantes, ya que sus constelaciones densamente pobladas generan regiones de alta ambigüedad que el LDA no logra separar completamente con un descriptor lineal.

En el grupo de modulaciones analógicas, AM-SSB-SC (73.7 %) y AM-DSB-SC (66.9 %) presentan confusión entre sí, lo que es consistente con el fenómeno de silencios en la señal portadora observado también en RadioML 2016. Estos resultados confirman que el KNN con LDA alcanza su límite en el dataset de 2018: las clases adicionales introducen una complejidad topológica que las proyecciones lineales y las métricas de distancia no pueden resolver completamente.

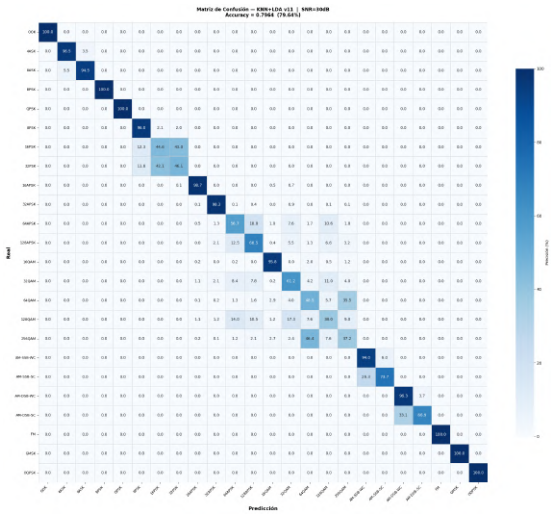


Figura 18. Matriz de Confusión KNN. Fuente: Autores

b) **K-Means**: K-Means es no supervisado, agrupa por distancia en el espacio de features sin ver etiquetas. Su bajo rendimiento en el dataset de 2018 tiene dos causas. Primero, más clases significa más centroides a estimar, y el algoritmo converge peor en espacios de alta dimensión. Segundo, las clases nuevas de 2018 son similares entre sí, entonces los clusters se superponen y las asignaciones fallan, por eso, aunque se aplicó normalización de potencia, eliminación de componente DC, extracción de características estadísticas, cumulantes de orden superior, representación I/Q enriquecida, PCA y sobre-segmentación mediante K-Means, el desempeño permaneció bajito. Esto evidencia que K-Means, al basarse únicamente en distancias euclidianas y asumir estructuras aproximadamente esféricas en el espacio de características, no resulta suficientemente robusto para separar 24 modulaciones RadioML, incluso en SNR alta.

K-Means no resulta adecuado como clasificador principal para identificar modulaciones en RadioML, especialmente cuando existen muchas clases de modulación. Su bajo rendimiento se debe a que el algoritmo no aprende patrones discriminativos, no aprovecha la estructura temporal completa de la señal I/Q y depende fuertemente de que las clases sean separables por distancia.

Otro punto importante es que K-Means es un método no supervisado. Durante el entrenamiento no usa las etiquetas reales de modulación, por lo tanto no aprende directamente qué diferencia a una clase de otra. Las etiquetas solo se usan después para evaluar los clusters y construir la matriz de confusión. Esto limita mucho su capacidad frente a modelos supervisados.

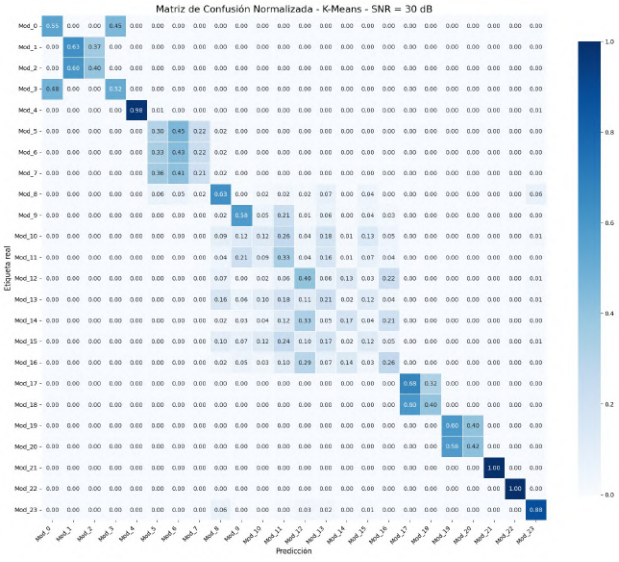


Figura 19. Matriz de Confusión K-Means. Fuente: Autores

c) **CNN**: La preparación de datos es más importante que la arquitectura misma. Si no se normalizan las señales mediante su energía intrínseca, la CNN se vuelve ”perezosa” clasifica basándose únicamente en la amplitud o volumen de la señal. Al normalizar, se obligó a CNN a buscar características puramente geométricas y frecuenciales, aumentando la precisión.

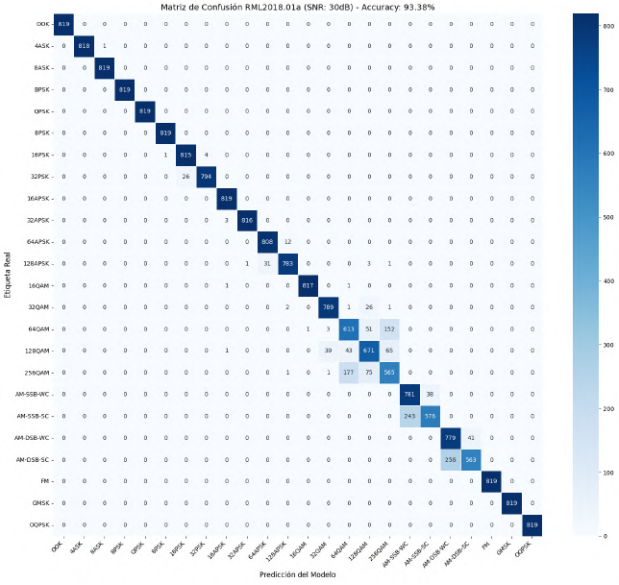


Figura 20. Matriz de Confusión CNN. Fuente: Autores

d) **RNN**: La inclusión de la fase diferencial ($\Delta\phi$) en el preprocesamiento fue el factor determinante para la estabilización del modelo. Mientras que la fase absoluta es vulnerable a los desplazamientos de frecuencia (Doppler o desalineación de osciladores), la fase diferencial actúa como la ”huella digital”geométrica de la modulación, permitiendo al modelo discriminar con alta fidelidad entre esquemas complejos como M-PSK y M-QAM. La implementación de técnicas de Gradient Clipping y Pooling Global resultó indispensable para mitigar el desvanecimiento y explosión del gradiente, demostrando que la estabilidad numérica es tan importante como el diseño de la arquitectura misma. En el mundo real de las telecomunicaciones, una relación señal-ruido (SNR) de 30 dB se considera un canal ”perfecto.º de laboratorio (casi sin ruido). Sin embargo, para una Inteligencia Artificial, 30 dB sin un preprocesamiento de sincronización puede ser indescifrable. Esto demuestra que la IA en telecomunicaciones no sufre por el ruido de canal, sino por la desorganización espacial de los datos si no se normalizan correctamente.

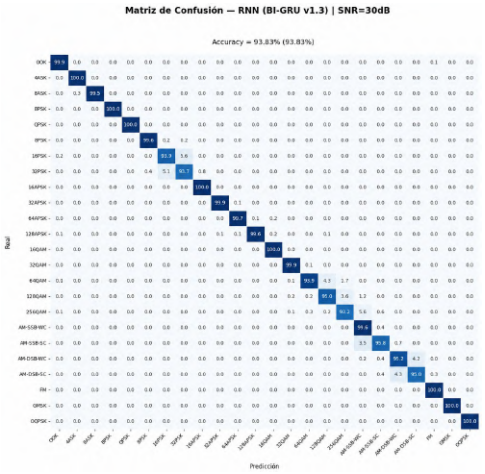


Figura 21. Matriz de Confusión RNN

Los resultados obtenidos sobre el dataset RadioML 2018 demuestran la superioridad de las arquitecturas de aprendizaje profundo frente a los métodos clásicos en la tarea de clasificación automática de modulaciones. RNN alcanzó la precisión más alta con un 94.72 %, seguida de CNN con un 93.60 %, lo que evidencia que ambas arquitecturas logran capturar eficazmente los patrones temporales y espectrales inherentes a las señales de radiofrecuencia, siendo RNN la más adecuada dada la naturaleza secuencial de dichas señales.

En síntesis, RNN es el modelo óptimo para la clasificación de modulaciones sobre RadioML 2018, con CNN como alternativa igualmente competitiva. La brecha de rendimiento entre los modelos de aprendizaje profundo y los métodos clásicos subraya la necesidad de emplear arquitecturas capaces de modelar dependencias temporales

cuando se trabaja con señales de comunicación de alta complejidad.

Cuadro III
PRECISIÓN DE LAS MODULACIONES

Modulación	Precisión
KNN	79.64 %
K-Means	49 %
CNN	93.60 %
RNN	93.83 %

VIII. CONCLUSIONES

El trabajo con el RadioML2018 fue mucho más complejo en comparación con el RadioML2016, dado que el primero posee clases con variantes de alta densidad (64QAM, 128QAM, 128APSK) que difieren solo en cuántos puntos de constelación tienen, además de ello, el dataset de 2018 toma una cantidad considerable de muestras, lo que lo convierte en un archivo robusto para su manejo. Un clasificador que tiene que separar 11 señales distintas puede funcionar con reglas relativamente simples; uno que tiene que separar 24, especialmente con tanta similitud entre clases vecinas, necesita tener representaciones más completas.

En el dataset de 2018 CNN y RNN obtuvieron una precisión de 93 %, en el dataset de 2016 su precisión no superó el 90 %, su mejoría se debió a que las redes aprenden representaciones directamente de las muestras IQ crudas, sin que nadie tenga que decidir qué features extraer. Con 1024 muestras por señal, hay más información temporal y espacial disponible para que la red aprenda. KNN, con un 79.64 %, mostró limitaciones significativas frente a la complejidad del dataset, ya que al aumentar la variedad de modulaciones su capacidad de generalización disminuye al depender exclusivamente de métricas de distancia en el espacio de características. Por su parte, K-Means obtuvo apenas un 49.00 %, resultado equivalente a una clasificación aleatoria, lo que confirma que los enfoques no supervisados carecen de la información necesaria para distinguir de manera confiable entre clases de modulación.

Como conclusión final para resolver el problema central del documento, la mejor alternativa para identificar de manera automática los cambios de modulación usando los dataset de 2016 y 2018 es CNN, dado que como se ha mencionado anteriormente, esta aprende automáticamente características discriminativas desde las señales I/Q, capturando patrones de amplitud, fase y estructura temporal que son importantes para diferenciar modulaciones.

REFERENCIAS

[1] Z. Huang, S. Denman, A. Pemasiri, C. Fookes, and T. Martin, "Few-shot radar signal recognition through self-supervised learning and radio frequency domain adaptation," in *2025 IEEE 35th International Workshop on Machine Learning for Signal Processing (MLSP)*, 2025, pp. 1–6.

[2] G. R. G. T. N. D. A. Rahul Mundlamuri, Devasena Inupakutika, "An rf modulation recognition method using machine learning," in *in Electronic Imaging*, vol. 366, 2023, pp. 1–5.

[3] K. Pijackova and T. Gotthans, "Radio modulation classification using deep learning architectures," in *2021 31st International Conference Radioelektronika (RADIOELEKTRONIKA)*, 2021, pp. 1–5.

[4] Z. Zhu, "Automatic modulation classification: Principles, algorithms and applications," accedido: 2026-05-26. [Online]. Available: https://book1.es/clasificacion-automatica-de-la-modulacion-principios-algoritmos-y-aplicaciones

[5] S. de Radiocomunicaciones de la UIT, "Medición y evaluación de la ocupación del espectro," *Informe UIT-R SM.2256-1*, 8, 2016.

[6] Studymaster, "Modulación analógica," accedido: 2026-05-18. [Online]. Available: https://www.studysmarter.es/resumenes/ingenieria/ingenieria-de-telecomunicaciones-ingenieria/modulacion-analogica/

[7] J. Chambi, "¿qué es la modulación digital?" accedido: 2026-05-18. [Online]. Available: https://www.soloingenieria.org/ingenieria-en-telecomunicaciones/modulacion-digital/

[8] Pinxau1000, "Conjunto de datos deepsig: Radioml 2018.01a," accedido: 2026-05-18. [Online]. Available: https://www.kaggle.com/datasets/pinxau1000/radioml2018

[9] "Antenas tdt: db, señal y normativas clave," accedido: 2026-05-26. [Online]. Available: https://radiofmtotal.com.ar/antena-fm-db-t/

[10] M. M. Fernandez, "Análisis de la calidad en modulaciones analógicas," accedido: 2026-05-18. [Online]. Available: https://www.lpi.tel.uva.es/~marcma/tts/pdfs/tema5.pdf

[11] E. Kavlakoglu, "¿qué es el algoritmo knn?" accedido: 2026-05-18. [Online]. Available: https://www.ibm.com/mx-es/think/topics/knn

[12] L. Ramírez, "Algoritmo k-means: ¿qué es y cómo funciona?" accedido: 2026-05-18. [Online]. Available: https://www.iebschool.com/hub/algoritmo-k-means-que-es-y-como-funciona-big-data/

[13] "¿qué es deep learning?" accedido: 2026-05-18. [Online]. Available: https://www.ibm.com/es-es/think/topics/deep-learning

[14] "Introducción a las redes neuronales convolucionales (cnn)," accedido: 2026-05-18. [Online]. Available: https://www.datacamp.com/es/tutorial/introduction-to-convolutional-neural-networks-cnns

[15] "Tutorial de redes neuronales recurrentes (rnn)," accedido: 2026-05-18. [Online]. Available: https://www.datacamp.com/es/tutorial/tutorial-for-recurrent-neural-network

[16] J. K. Maguana Zhindón and R. A. Reino Criollo, "Modulación adaptativa para un sistema OFDM, utilizando técnicas de Machine Learning," 2024.

[17] C. E. Mosquera Trujillo, "Automatic modulation classification for software defined radios: A deep learning approach," 2025.

[18] T. J. O'Shea, T. Roy, and T. C. Clancy, "Over-the-air deep learning based radio signal classification," *IEEE Journal of Selected Topics in Signal Processing*, vol. 12, no. 1, pp. 168–179, 2018.

[19] C. A. B.-D. J. C. Martínez-Quintero, E. P. Estupiñan-Cuesta, "Design and implementation of a digital modulation classification system using intelligent algorithms, visión electrónica," pp. 237–248, 2023.

[20] "16 qam vs 64 qam vs 256 qam modulation: Differences and applications," accedido: 2026-05-26. [Online]. Available: https://www.rfwireless-world.com/terminology/16-qam-vs-64-qam-vs-256-qam